

Apprentissage statistique supervisé : Prédiction par minimisation du risque empirique

Alexandre Autran, Pierre Badra, Marius Lebreton

Groupe de lecture
20 janvier 2026

Plan

- 1 Définitions
- 2 Borne de risque
- 3 Dimension de Vapnik-Chervonenkis
- 4 Convexification

Soit $\mathcal{X}$ et $\mathcal{Y}$ deux espaces mesurés. On observe des données i.i.d.

$$(X_1, Y_1), \dots, (X_n, Y_n) \sim \mathbb{P}$$

où :

- $X \in \mathcal{X}$ est une observation et $Y \in \mathcal{Y}$ est une étiquette.
- $\mathbb{P}$ est une loi inconnue sur $\mathcal{X} \times \mathcal{Y}$.
- On note $\mathcal{F}$ l'ensemble des fonctions mesurables de $\mathcal{X}$ dans $\mathcal{Y}$.

Objectif

Étant donnés un modèle $S \subset \mathcal{F}$ et une fonction de perte $\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_+$ mesurable, construire un prédicteur $f \in S$ minimisant *l'erreur de prévision*

$$R_{\mathbb{P}}(f) = \mathbb{E}[\ell(f(X)), Y)].$$

Définition (risque empirique)

Le *risque empirique* (ou *erreur d'apprentissage*) d'un prédicteur f mesurée avec la perte ℓ est

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(X_i), Y_i) = R_{\mathbb{P}_n}(f).$$

où $\hat{\mathbb{P}}_n := \frac{1}{n} \sum_{i=1}^n \delta_{(X_i, Y_i)}$.

Définition (Minimiseur du risque empirique)

On dit que f est un *minimiseur du risque empirique* sur $S \subset \mathcal{F}$ si $f \in S$ et si $f \in \arg \min_{g \in S} \hat{R}_n(g)$

Remarque. La loi des grands nombres donne $\hat{R}_n(f) \rightarrow R(f)$ pour un f fixé.

Définition (Erreur d'estimation)

L'excès de risque associé à un prédicteur $f \in S$ est la quantité

$$\ell(f^*, f) := R_P(f) - R_P^*, \quad \text{où } R_P^* = \inf_{g \in \mathcal{F}} R_P(g).$$

L'erreur d'approximation du modèle S est alors la quantité

$$\ell(f^*, S) := \inf_{f \in S} \ell(f^*, f).$$

L'erreur d'estimation de $f \in S$ est la quantité

$$\ell(f^*, f) - \ell(f^*, S) \geq 0.$$

Remarque. L'excès de risque est la quantité que l'on souhaite minimiser.

Idée : On a $\ell(f^*, f) = \underbrace{\ell(f^*, S)}_{\text{erreur d'approximation}} + \underbrace{\ell(f^*, f) - \ell(f^*, S)}_{\text{erreur d'estimation}}.$

Proposition

Soit $\hat{f}_n$ un minimiseur du risque empirique sur S . Alors

$$\ell(f^*, \hat{f}_n) - \ell(f^*, S) \leq 2 \sup_{f \in S} |R(f) - R_n(f)|$$

et

$$\mathbb{E}[\ell(f^*, \hat{f}_n) - \ell(f^*, S)] \leq \mathbb{E}[\sup_{f \in S} R(f) - R_n(f)]$$

Minimiser l'excès de risque revient en fait à minimiser l'écart entre le risque "général" et le risque empirique.

Dans la suite, on se place dans le cas de la classification supervisée binaire : $\mathcal{Y} = \{-1, 1\}$.

Dans ce cadre, on parle de :

- *classifieur* au lieu de prédicteur.
- *dictionnaire* $\mathcal{D}$ au lieu de modèle $\mathcal{F}$.

On a plus simplement (avec $\ell(y, y') = \mathbb{1}_{y \neq y'}$) :

$$R(h) := \mathbb{E}[\ell(h(X)), Y] = \mathbb{P}(Y \neq h(X)),$$

et

$$\hat{R}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Y_i \neq h(X_i)\}} = \hat{\mathbb{P}}_n(Y \neq h(X)).$$

où $\hat{\mathbb{P}}_n := \frac{1}{n} \sum_{i=1}^n \delta_{(X_i, Y_i)}$.

Remarques.

- $R(h)$ est minimal pour la *classifieur de Bayes*

$$h_*(X) := \text{sign}(\mathbb{E}(Y|X)).$$

Or $\mathbb{P}$ est inconnue donc on ne peut pas calculer h^* .

- $\hat{R}_n(h)$ est minimal pour $\hat{h}_{\mathcal{D}} \in \arg \min_{h \in \mathcal{D}} \hat{R}_n(h)$.

Questions :

- Quel dictionnaire $\mathcal{D}$ choisir ?
- Comment $\hat{h}_{\mathcal{D}}$ se comporte par rapport à h_* ?

On décompose :

$$0 \leq R(\hat{h}_{\mathcal{D}}) - R(h_*) = \underbrace{\min_{h \in \mathcal{D}} R(h_{\mathcal{D}}) - R(h_*)}_{\text{erreur d'approximation}} + \underbrace{R(\hat{h}_{\mathcal{D}}) - \min_{h \in \mathcal{D}} R(h)}_{\text{erreur d'estimation}}.$$

Remarque.

- Le premier terme décroît quand la taille du dictionnaire augmente.
- Le second terme mesure l'écart dû au caractère aléatoire des données, et ce terme (contrairement à l'erreur d'approximation) peut croître avec la taille du dictionnaire et provoquer le sur-apprentissage.




Figure – À gauche : classifieurs linéaires $\mathcal{D}_{\text{lin}}$. Au centre : classifieurs polygonaux $\mathcal{D}_{\text{poly}}$. À droite : classifieurs basés sur des formes quadratiques.

On cherche alors une borne sur l'erreur d'estimation.

Définition (Coefficient d'éclatement/pulvérisation)

Pour un dictionnaire $\mathcal{D}$ et $n \geq 1$, on définit

$$\Pi_{\mathcal{D}}(n) = \max_{(x_1, \dots, x_n) \in \mathcal{X}^n} \#\{(h(x_1), \dots, h(x_n)) \mid h \in \mathcal{D}\}.$$

Remarque. $\Pi_{\mathcal{D}}(n)$ est le nombre maximal d'étiquetages de n points réalisables par les classifieurs de $\mathcal{D}$.

Théorème (Bornes de risque)

Pour tout $t > 0$, nous avons avec probabilité au moins $1 - e^{-t}$, on a

$$R(\hat{h}_{\mathcal{D}}) - \min_{h \in \mathcal{D}} R(h) \leq 4 \sqrt{\frac{2 \log(2\Pi_{\mathcal{D}}(n))}{n}} + \sqrt{\frac{2t}{n}}$$

avec pour rappel $\hat{h}_{\mathcal{D}} \in \arg \min_{h \in \mathcal{D}} \hat{R}_n(h)$.

Théorème (Fluctuations)

$$|R(\hat{h}_{\mathcal{D}}) - \hat{R}_n(\hat{h}_{\mathcal{D}})| \leq 2 \sqrt{\frac{2 \log(2\Pi_{\mathcal{D}}(n))}{n}} + \sqrt{\frac{t}{2n}}.$$

Soit $\{\mathcal{D}_1, \dots, \mathcal{D}_M\}$ une collection de dictionnaires de classifieurs.
Pour chaque $m \in \{1, \dots, M\}$, on note $\hat{h}_{\mathcal{D}_m} \in \arg \min_{h \in \mathcal{D}_m} \hat{R}_n(h)$.

L'objectif idéal serait de choisir le *dictionnaire oracle*

$$\mathcal{D}^* \in \arg \min_{\mathcal{D} \in \{\mathcal{D}_1, \dots, \mathcal{D}_M\}} R(\hat{h}_{\mathcal{D}}),$$

mais ce choix dépend de la loi inconnue $\mathbb{P}$.

Problème

Sélectionner le dictionnaire en minimisant le risque empirique $\hat{R}_n(\hat{h}_{\mathcal{D}_m})$ favorise systématiquement les dictionnaires les plus riches : sur-apprentissage.

L'idée est de prendre en compte les fluctuations de $\hat{R}_n(\hat{h}_{\mathcal{D}})$ autour de $R(\hat{h}_{\mathcal{D}})$, en s'appuyant sur la 2ème inégalité du théorème.

On sélectionne le dictionnaire $\mathcal{D}_{\hat{m}}$ tel que

$$\hat{m} \in \arg \min_{m=1,\dots,M} \left(\hat{R}_n(\hat{h}_{\mathcal{D}_m}) + \text{pen}(\mathcal{D}_m) \right),$$

avec la pénalité $\text{pen}(\mathcal{D}) := 2\sqrt{\frac{2 \log(2\Pi_{\mathcal{D}}(n))}{n}}$.

Théorème (Sélection de dictionnaire)

Pour tout $t > 0$, avec probabilité au moins $1 - e^{-t}$,

$$R(\hat{h}_{\mathcal{D}_{\hat{m}}}) \leq \min_{m=1,\dots,M} \left\{ \inf_{h \in \mathcal{D}_m} R(h) + 2 \text{pen}(\mathcal{D}_m) \right\} + \sqrt{\frac{2 \log M + 2t}{n}}.$$

Remarque. La procédure réalise une performance proche de celle du dictionnaire oracle.

Cas d'un modèle fini

On étudie le cas d'un ensemble de prédicteurs fini $S \subset \mathcal{F}$. On se donne f_S un minimiseur du risque empirique sur S .

Proposition

On suppose que le risque R_p et le risque $\hat{R}_n$ sont associés à une même fonction de coût c et qu'il existe $a < b$ des constantes telles que pour tout $f \in S$,

$$c(f(X), Y) \in [a, b], \quad \text{presque sûrement.}$$

Alors, pour tout $x \geq 0$ et tout $n \geq 1$,

$$\mathbb{P} \left(\ell(f^*, f_S(D_n)) - \ell(f^*, S) \leq (b - a) \sqrt{\frac{2(x + \ln(2\#S))}{n}} \right) \geq 1 - e^{-x}.$$

Pour prouver ce résultat, on rappelle l'inégalité de Hoeffding.

Théorème (Inégalité de Hoeffding)

Soient $\xi_1, \dots, \xi_n$ des variables aléatoires indépendantes telles qu'il existe a_i, b_i vérifiant

$$a_i \leq \xi_i \leq b_i, \quad \text{presque sûrement.}$$

Alors, pour tout $z \geq 0$,

$$\mathbb{P} \left(\left| \sum_{i=1}^n \xi_i - \mathbb{E}[\xi_i] \right| \geq z \right) \leq 2 \exp \left(\frac{-2z^2}{\sum_{i=1}^n (b_i - a_i)^2} \right).$$

On doit contrôler toutes les fonctions de S pour obtenir cette inégalité. Si $\#S$ est très grand, n doit être très grand pour rendre la borne petite.

On dispose d'un résultat similaire avec les espérances.

Proposition

Avec les mêmes hypothèses que la proposition précédente, on a pour $n \geq 1$,

$$\mathbb{E}[\ell(f^*, f_S(D_n)) - \ell(f^*, S)] \leq (b - a) \sqrt{\frac{\ln(\#S)}{2n}}.$$

Au lieu de majorer par le cardinal de S , i.e. considérer toutes les fonctions, nous allons majorer par $\Pi_S(n)$, le nombre d'étiquetages possible.

Cas d'un modèle quelconque

On se place dans le cadre de la classification binaire avec le coût $0 - 1$, i.e.

$$\ell : (y, y') \mapsto \mathbb{1}_{y \neq y'}.$$

L'ensemble $B_S(D_n) := \{(\mathbb{1}_{f(x_i) \neq y_i})_{i=1, \dots, n} \mid f \in S\} \subset \{0, 1\}^n$ est fini, même si S est infini.

Lemme

Soient $B \subset \mathbb{R}^n$ un ensemble fini et $\varepsilon_1, \dots, \varepsilon_n$ des variables de Rademacher indépendantes. Alors,

$$\mathbb{E} \left[\max_{\beta \in B} \sum_{i=1}^n \beta_i \varepsilon_i \right] \leq \sqrt{2 \ln(\#B) \max_{\beta \in B} \sum_{i=1}^n \beta_i^2}.$$

En utilisant le lemme précédent, on obtient

$$\mathbb{E} \left[\sup_{f \in S} \{R_P(f) - \hat{R}_n(f)\} \right] \leq \frac{2\sqrt{2}}{\sqrt{n}} \sqrt{\ln(\#B_S(D_n))}$$

C'est la même égalité que l'on a vu précédemment en ayant remplacé le cardinal de S par celui de $B_S(D_n)$, à un facteur 4 près. Comme

$$\#B_S(D_n) = \#\{(f(X_i))_{i=1,\dots,n} \mid f \in S\},$$

on peut exprimer cette égalité à l'aide du coefficient de pulvérisation

$$\mathbb{E} \left[\sup_{f \in S} \{R_P(f) - \hat{R}_n(f)\} \right] \leq \frac{2\sqrt{2}}{\sqrt{n}} \sqrt{\ln(\Pi_S(n))}$$

Définition (Classe de Vapnik-Chervonenkis)

Un ensemble S de prédicteurs est une classe de Vapnik-Chervonenkis si

$$V(S) := \sup\{n \geq 1 \mid \Pi_S(n) = 2^n\} < +\infty.$$

$V(S)$ est la dimension de Vapnik-Chervonenkis de S .

Théorème (Lemme de Sauer)

Soit S une classe de Vapnik-Chervonenkis. Pour tout $x_1, \dots, x_n \in \mathcal{X}$

$$\#\{f(x_1), \dots, f(x_n) \mid f \in S\} \leq \sum_{i=0}^{V(S)} \binom{n}{i} \leq \left(\frac{en}{V(S)} \right)^{V(S)}.$$

Si $n > 2V(S)$, on a

$$\ln(\#\{f(x_1), \dots, f(x_n) \mid f \in S\}) \leq V(S) \ln \left(\frac{en}{V(S)} \right).$$

En combinant les inégalités précédentes, on obtient

$$\mathbb{E} \left[\sup_{f \in S} \{R_P(f) - \hat{R}_n(f)\} \right] \leq 2\sqrt{2} \sqrt{\frac{V(S)}{n} \ln \left(\frac{en}{V(S)} \right)}$$

Pourquoi convexifier le risque empirique ?

La minimisation du risque empirique en classification

$$\widehat{R}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Y_i h(X_i) < 0\}}$$

présente de bonnes garanties statistiques, mais :

- la perte $z \mapsto \mathbb{1}_{z < 0}$ et l'ensemble des classifieurs $\mathcal{D}$ sont en général **non convexe**,
- le problème est **difficile numériquement**.

Pour cela on

- remplace la perte indicatrice par une **perte convexe** ℓ ,
- remplace $\mathcal{D}$ par un **ensemble fonctionnel convexe** $\mathcal{F} \subset \mathbb{R}^{\mathcal{X}}$,
- classifie ensuite par le signe de la fonction obtenue.

Dans le cadre convexe, on ne travaille plus directement avec des classifieurs $h : \mathcal{X} \rightarrow \{-1, +1\}$, mais avec des fonctions

$$f : \mathcal{X} \rightarrow \mathbb{R}, \quad \mathcal{F} \subset \mathbb{R}^{\mathcal{X}} \text{ convexe.}$$

Une fonction $f \in \mathcal{F}$ induit le classifieur

$$h_f(x) = \text{sign}(f(x)).$$

et le risque empirique de classification est

$$\widehat{R}_n(\text{sign}(f)) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Y_i f(X_i) < 0\}}.$$

La perte indicatrice $z \mapsto \mathbb{1}_{\{z < 0\}}$ est remplacée par une fonction de perte convexe $z \mapsto \ell(z)$. On définit alors

$$\widehat{R}_n^\ell(f) := \frac{1}{n} \sum_{i=1}^n \ell(Y_i f(X_i)).$$

La problème devient donc

$$\widehat{f}_{\mathcal{F}} \in \arg \min_{f \in \mathcal{F}} \widehat{R}_n^\ell(f), \quad \widehat{h}_{\mathcal{F}} = \text{sign}(\widehat{f}_{\mathcal{F}}).$$

Remarque. Ce problème, désormais convexe, est calculable efficacement.

On choisit en général une perte ℓ : convexe, décroissante, positive, vérifiant $\ell(z) \geq \mathbb{1}_{\{z < 0\}}$.

Exemples standards de pertes

- *Perte exponentielle* :

$$\ell(z) = e^{-z}.$$

- *Perte logit* :

$$\ell(z) = \log(1 + e^{-z}).$$

- *Perte hinge* :

$$\ell(z) = (1 - z)_+ = \max(0, 1 - z).$$

Remarque. Ces pertes sont des relaxations convexes de la perte $\ell(z) = \mathbb{1}_{\{z < 0\}}$.

Exemple d'espace fonctionnel

Combinaisons linéaires de classifieurs (boosting) :

$$\mathcal{F} = \left\{ x \mapsto f(x) = \sum_{j=1}^p \beta_j h_j(x), \quad \beta \in \mathcal{C} \right\},$$

où $\mathcal{C} \subset \mathbb{R}^p$ est un ensemble convexe, et les h_j sont des classifieurs.

Théorème

Pour tout $R > 0$, on définit

$$\Delta\ell(R) := |\ell(R) - \ell(-R)|.$$

On suppose ℓ convexe, décroissante, positive, α -Lipschitz sur $[-R, R]$, et telle que $\ell(z) \geq \mathbb{1}_{\{z < 0\}}$.

Alors si $\mathcal{C}$ est la boule de centre 0 et de rayon R pour la norme 1 dans $\mathbb{R}^p$, on a avec probabilité au moins $1 - e^{-t}$:

$$R(\hat{h}_{\mathcal{F}}) \leq \hat{R}_n^{\ell}(\hat{f}_{\mathcal{F}}) + 2\alpha R \sqrt{\frac{2 \log(2p)}{n}} + \Delta\ell(R) \sqrt{\frac{t}{2n}}$$

Merci pour votre écoute

Références :

- Sylvain Arlot, *Fondamentaux de l'apprentissage statistique*, 2018.
<https://hal.archives-ouvertes.fr/hal-01485506/document>
- Christophe Giraud, *Fondements mathématiques de l'apprentissage statistique*, cours de l'École Polytechnique.
<http://www.math.polytechnique.fr/xups/xups13-02.pdf>
- Clément Levrard, *Apprentissage statistique et grande dimension*, notes de cours 2023.
https://www.normalesup.org/~levrard/APPR_Poly.pdf